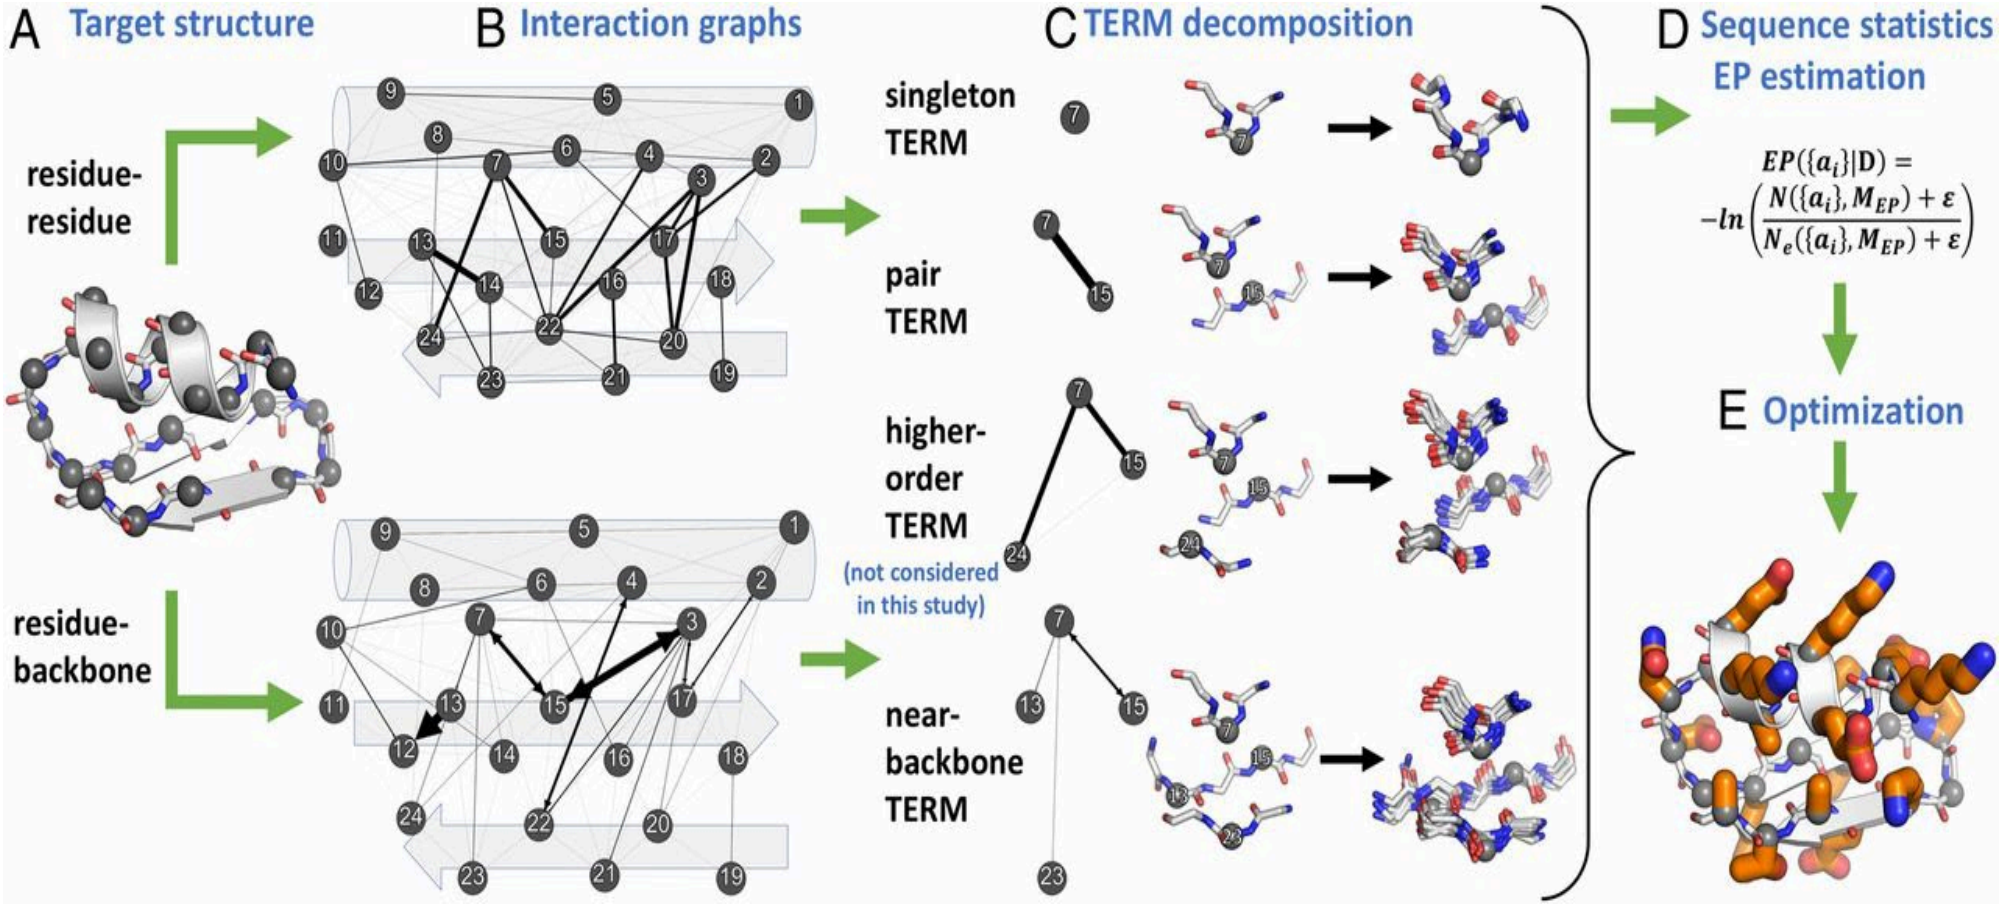
MODELADO MATEMÁTICO DE BIOMOLECULAS



Juan M. Ruso
Dpto. Física Aplicada
juanm.ruso@usc.es

1. MODELOS GEOMÉTRICOS DEL ADN

Geometría diferencial de curvas

$$\vec{r}(t) = x(t)\vec{\imath} + y(t)\vec{\jmath} + z(t)\vec{k}$$

$$s = \int_a^b \sqrt{[x'(t)]^2 + [y'(t)]^2 + [z'(t)]^2}\,dt = \int_a^b \left\|\vec{r'}(t)\right\| dt$$

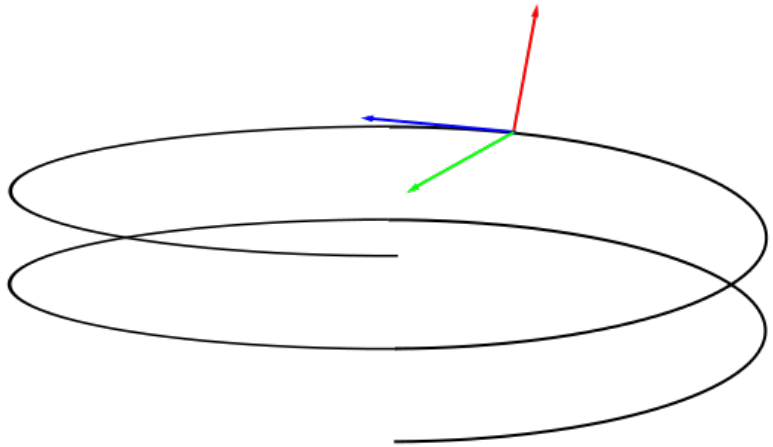
$$\vec{r}(s) = x(s)\vec{\imath} + y(s)\vec{\jmath} + z(s)\vec{k}$$

Triedro Móvil o ecuaciones de Frenet-Serret

$$\begin{cases} \vec{T}(t) = \vec{N}(t) \times \vec{B}(t) & Vector\ tangente \\ \vec{B}(t) = \vec{T}(t) \times \vec{N}(t) & Vector\ binormal \\ \vec{N}(t) = \vec{B}(t) \times \vec{T}(t) & Vector\ normal \end{cases}$$

$$\begin{cases} \vec{T}(t) = \dfrac{\vec{r}'(t)}{\|\vec{r}'(t)\|} \\ \vec{B}(t) = \dfrac{\vec{r}'(t) \times \vec{r}''(t)}{\|\vec{r}'(t) \times \vec{r}''(t)\|} \\ \vec{N}(t) = \dfrac{[\vec{r}'(t) \times \vec{r}''(t)] \times \vec{r}'(t)}{\|[\vec{r}'(t) \times \vec{r}''(t)] \times \vec{r}'(t)\|} \end{cases} \qquad \begin{cases} \vec{T}(s) = \dfrac{d\vec{r}}{ds} \\ \vec{N}(s) = \dfrac{1}{\kappa}\dfrac{d\vec{T}(s)}{ds} \\ \vec{B}(s) = \dfrac{1}{\tau}\left(\dfrac{d\vec{N}(s)}{ds} + \kappa\vec{T}(s)\right) \end{cases}$$

Donde κ es la curvatura y τ es la torsión



Vista esquemática de T, N y B de una curva hélice

$$\begin{cases} \kappa(t) = \dfrac{\|\vec{r}'(t) \times \vec{r}''(t)\|}{\|\vec{r}'(t)\|^3} \\ \tau(t) = \dfrac{\vec{r}(t) \cdot \left(\vec{r}''(t) \times \vec{r}'''(t)\right)}{\|\vec{r}'(t) \times \vec{r}''(t)\|^2} \end{cases} \qquad \begin{cases} \kappa(s) = \|\vec{r}''(s)\| \\ \tau(s) = \dfrac{\vec{r}'(s) \cdot \left(\vec{r}''(s) \times \vec{r}'''(s)\right)}{\|\vec{r}''(s)\|^2} \end{cases}$$

Parametrización de la hélice de ADN

$$\begin{cases} x = r\cos(\omega t) \\ y = -r\sin(\omega t) \\ z = kt \end{cases}$$

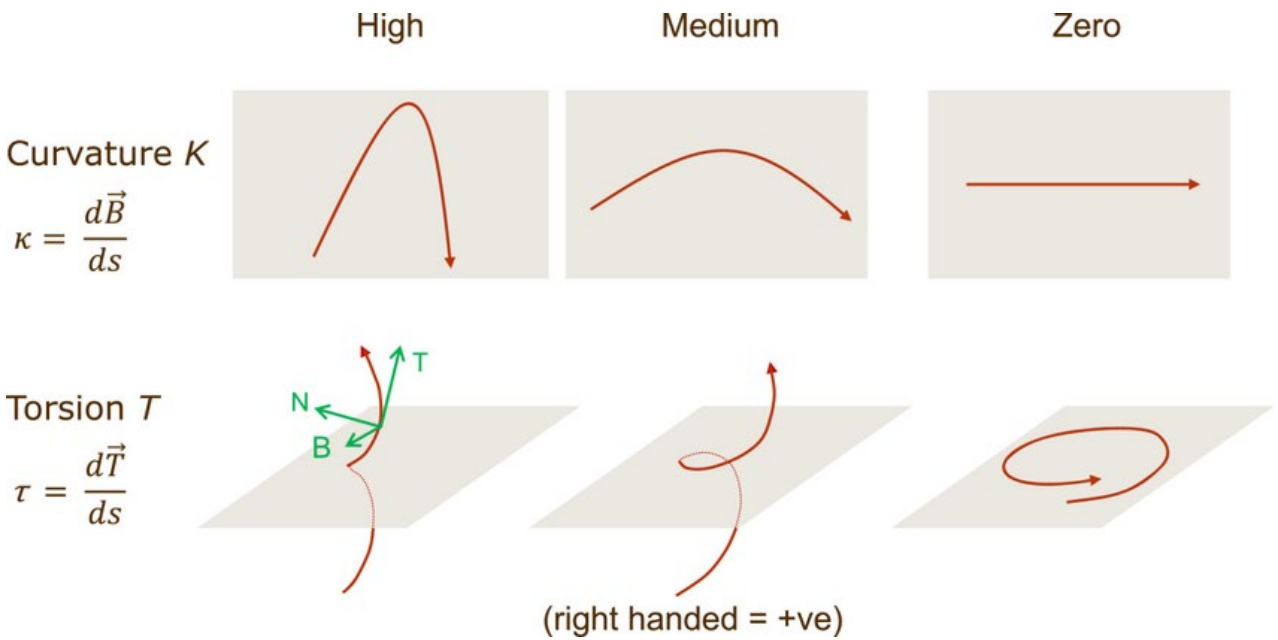
En esta parametrización r es el radio de giro, κ el avance en el sentido de giro y ω el ángulo girado por unidad de tiempo. Además, como la hélice de ADN es dextrógira elegimos para y signo negativo. Con esta parametrización tendremos representados todos los puntos de la hélice en función del tiempo.

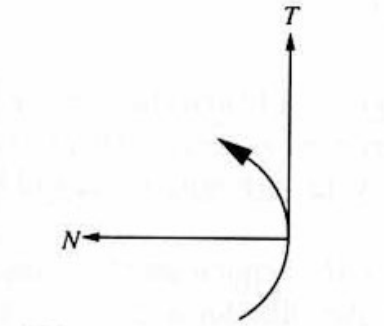
Para calcular los parámetros de la hélice usamos la longitud de arco, ya que en general las operaciones son más simples:

$$\vec{r}(s) = (r\cos(\omega s a), -r\sin(\omega s a), ksa) \qquad a = (r^2\omega^2 + k^2)^{-1/2}$$

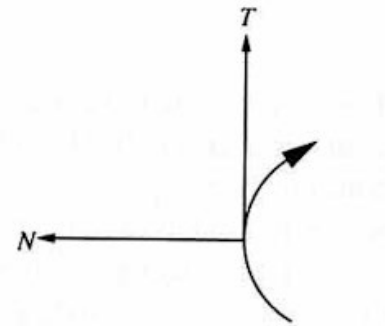
$$\kappa(s) = r\omega^2 a^2 \qquad \tau(s) = -r\omega a^2 k$$

Ambas magnitudes son constantes y no dependen del parámetro de la longitud de arco (hélice ideal).
El signo menos de la torsión denota hacia dónde va.

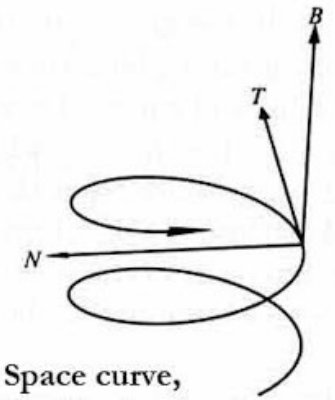




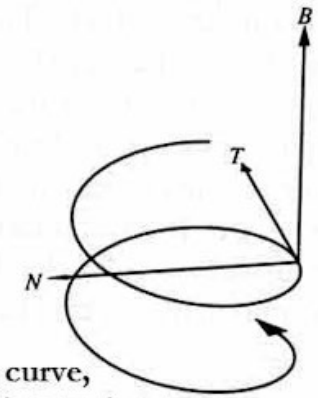
Plane curve,
Positive curvature kappa



Plane curve,
Negative curvature kappa



Space curve,
Positive torsion tau



Space curve,
Negative torsion tau

OTROS MODELOS

Modelo de Curvatura Persistente (Worm-like Chain, WLC)

Este modelo describe el ADN como un polímero semiflexible y se basa en la longitud de persistencia Lp, que es la medida de la rigidez de la cadena. En el modelo WLC, la energía asociada a la curvatura de la molécula está relacionada con la probabilidad de encontrar una configuración particular de la cadena

Ecuación de curvatura persistente:

$$E = \frac{k_B T}{2L_p} \int_0^L \left(\frac{d\hat{t}(s)}{ds} \right)^2 ds$$

$\hat{t}(s)$ es el vector tangente en el punto s, L la longitud total de la cadena.

Función de distribución de probabilidades $$P(\theta) = \frac{\sin(\theta)}{2L_p} \exp\left(-\frac{L}{2L_p} (1 - \cos(\theta)) \right)$$

θ es el ángulo entre las tangentes de dos puntos separados por una distancia L.

Este modelo es especialmente útil para estudiar la estructura a escala micrométrica, como el superenrollamiento y la compactación del ADN.

Modelo de Alambre Semiflexible

Este modelo extiende el WLC, pero con un enfoque en la elasticidad de la torsión y la curvatura del ADN. La energía elástica asociada a las deformaciones de torsión y curvatura está dada por:

$$E = \frac{1}{2}\int_0^L \left(A\,\kappa(s)^2 + C\,\tau(s)^2 \right) ds$$

A es el módulo de rigidez de curvatura, C es el módulo de rigidez torsional, $\kappa\, y\, \tau$ son la curvatura y la torsión en s

Este modelo se aplica en situaciones donde se necesita modelar cómo la elasticidad afecta a la conformación del ADN, como cuando se somete a tensiones mecánicas

Modelo de Hélice de Kirchhoff

El modelo de Kirchhoff describe el ADN como una hélice elástica, utilizando ecuaciones de equilibrio derivadas de la teoría de vigas de Kirchhoff. Este enfoque permite modelar las transiciones conformacionales entre las formas A, B, y Z del ADN.

Ecuaciones de Kirchhoff para una hélice:

$$\frac{d\mathbb{M}}{ds} + \mathbb{F} \times \mathbb{r}(s) = 0$$

$\mathbb{M}$ es el momento torsional a lo largo de la molécula, $\mathbb{F}$ es la fuerza aplicada, $\mathbb{r}$ es la posición del punto s.

En este modelo, el ADN es tratado como una viga elástica con curvatura y torsión variables. Es útil para estudiar fenómenos como el superenrollamiento, donde el ADN se enrolla sobre sí mismo generando tensiones internas.

Modelo de ADN como Cuerda Elástica (Wave Equation Model)

Este modelo describe el comportamiento dinámico del ADN utilizando la ecuación de onda. Aquí, el ADN se modela como una cuerda elástica, donde las ondas longitudinales y transversales describen las fluctuaciones dinámicas a lo largo de la molécula.

$$\frac{\partial^2 u}{\partial t^2} = v^2 \frac{\partial^2 u}{\partial x^2}$$

u(x,t) es el desplazamiento de la cuerda (ADN) y v es la velocidad de propagación de las ondas a lo largo del ADN.

En este modelo, las ondas solitónicas (solitones) pueden describir las aperturas localizadas de las hélices del ADN, que son importantes para la transcripción y replicación.

Solitones en ADN

$$\psi(x,t) = A\, sech^2\left(\frac{x - vt}{w}\right)$$

A es la amplitud del solitón y w es su anchura

Modelo de Peyrard-Bishop-Dauxois (PBD)

El modelo PBD es un modelo no lineal que se utiliza para describir la dinámica del ADN, especialmente la apertura de la doble hélice. En este enfoque, el ADN se modela como una cadena de osciladores acoplados con interacciones no lineales entre las bases complementarias.

Hamiltoniano del modelo $$H = \sum_n \left[\frac{p_n^2}{2m} + V(y_n) + W(y_n, y_{\{n-1\}}) \right]$$

p_n es el momento asociado con el desplazamiento de la n-ésima base, $V(y_n)$ el potencial de interacción no lineal entre las bases, $W(y_n, y_{\{n-1\}})$ es la interacción entre bases adyacentes.

Este modelo se utiliza para estudiar la desnaturalización del ADN y cómo las hélices se abren y cierran bajo condiciones térmicas.

Potencial Morse: $V(y) = D(1 - e^{-ay})^2$

Este potencial modela la interacción entre bases complementarias y describe el comportamiento de apertura de la doble hélice.

2. TOPOLOGIAS COMPLEJAS DE ADN

Casi todas las propiedades físicas, químicas y biológicas del ADN (comportamiento hidrodinámico, densidad, actividad de replicación y transcripción, enzimología, etc.) resultan afectadas el estado conformacional ADN

Se han utilizado diferentes sistemas matemáticos para el estudio del superenrollamiento. Una de la que mejor describe el fenómeno:

$$L_k = T_W \pm W_r$$

L_k representa las veces que una cadena de ADN se envuelve sobre otra. ADN con giro en sentido horario (formas A y B) L_k es positivo. ADN con giro en sentido antihorario (forma Z) su valor es negativo.

T_W es el número de vueltas completas (360°) de hélice.

W_r representa la cantidad de vueltas de sobreenrollamiento de una molécula de ADN circular. (+ en sentido horario y viceversa).

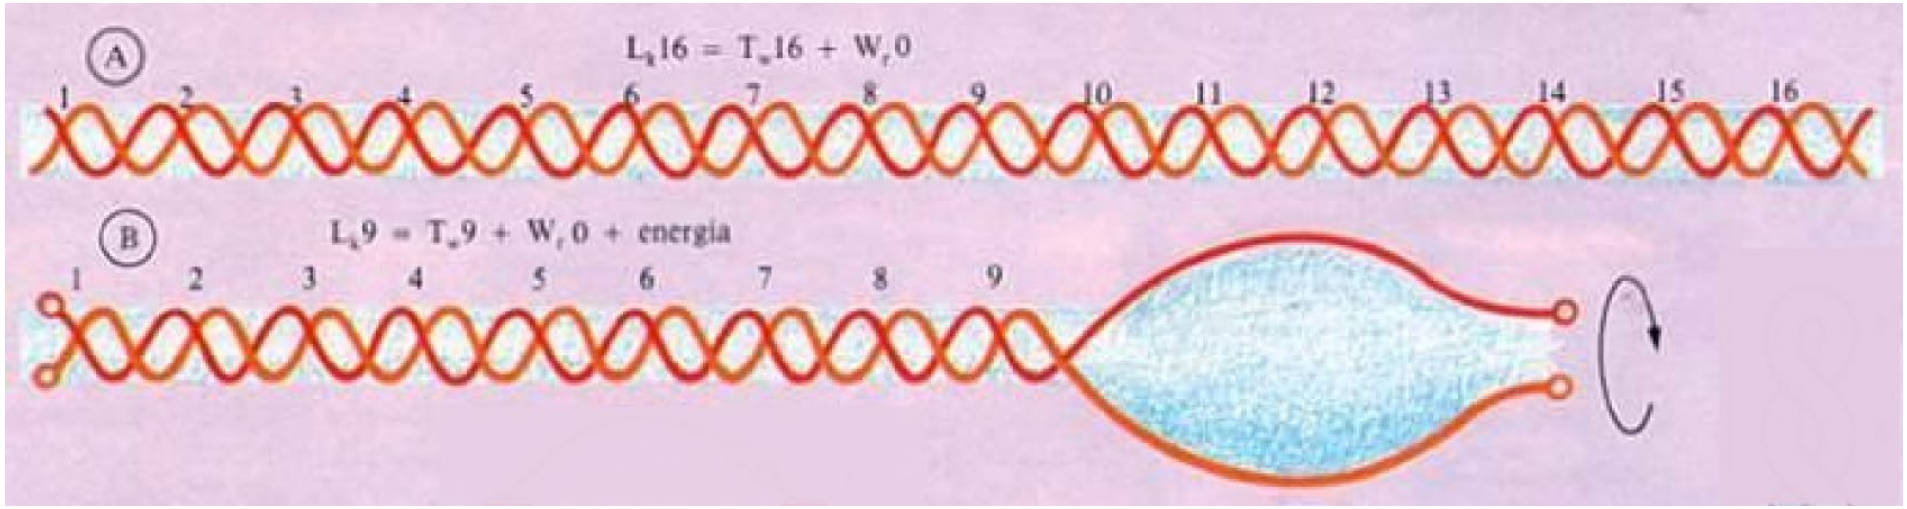
ADN lineal o ADN circular relajado (sin superenrollamiento): $W_r = O$ y $L_k = T_W$

Sea una cadena lineal de ADN de 160 pares de bases (cada 10 pares la hélice gira una vuelta completa):

$L_k = 16$ y $L_k = T_W$

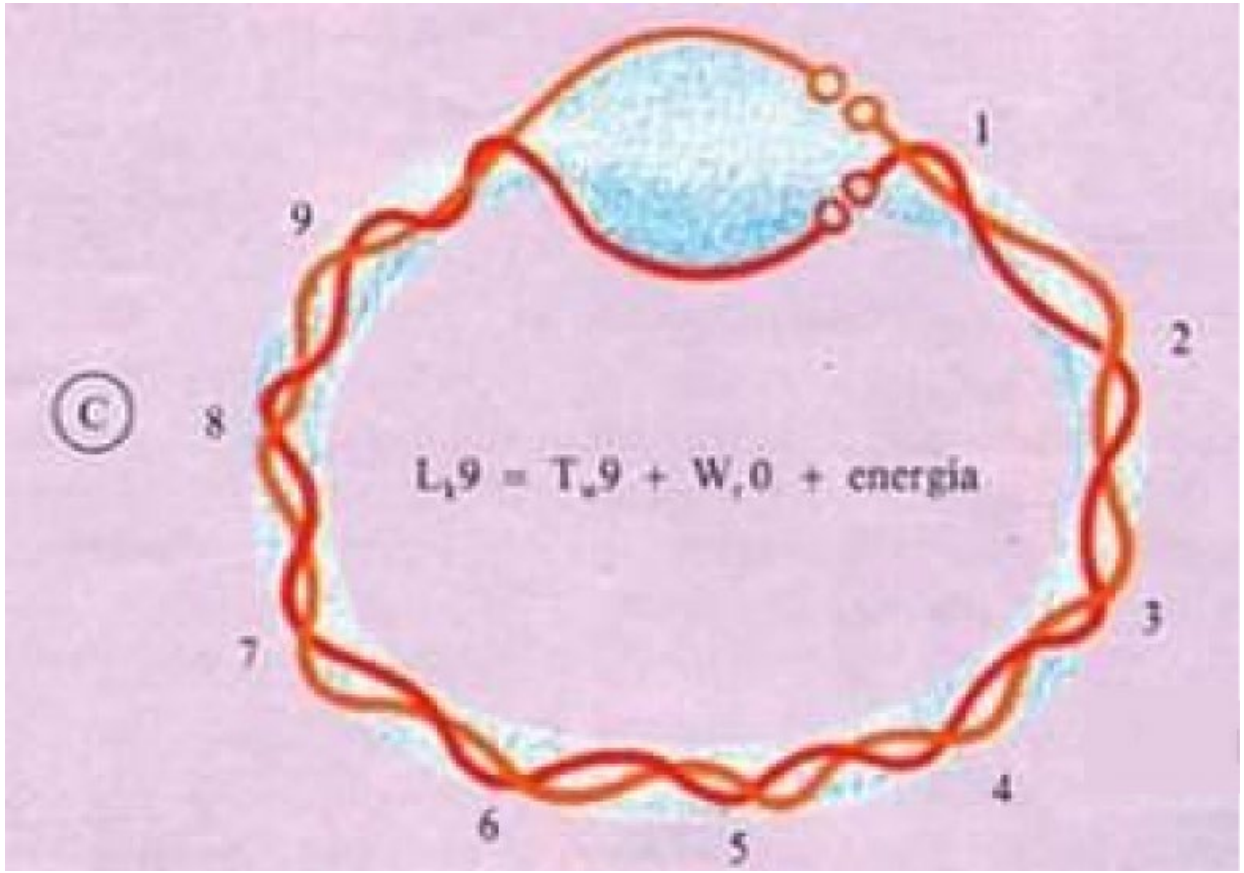
Ahora fijamos el extremo izquierdo de la cadena y le damos al derecho siete vueltas en el sentido de las agujas del reloj: disminución de L_k y de T_W que adquirirán el valor 9 (caso B).

Debido al a elasticidad del ADN, la molécula intentará retornar a su estado de reposo inicial con valores de 16 tanto para L_k como para T_W y en consecuencia, si se desea mantenerla en el estado al que se la ha forzado, será necesario el empleo de un vínculo externo.



Ahora unimos los dos extremos del ADN y lo transformamos en circular (caso C).

Para mantenerlo en forma de círculo relajado se deberá seguir aplicando la acción externa a fin de contrarrestar la tendencia de la molécula de ADN a recuperar los valores originales de L_k y T_W.

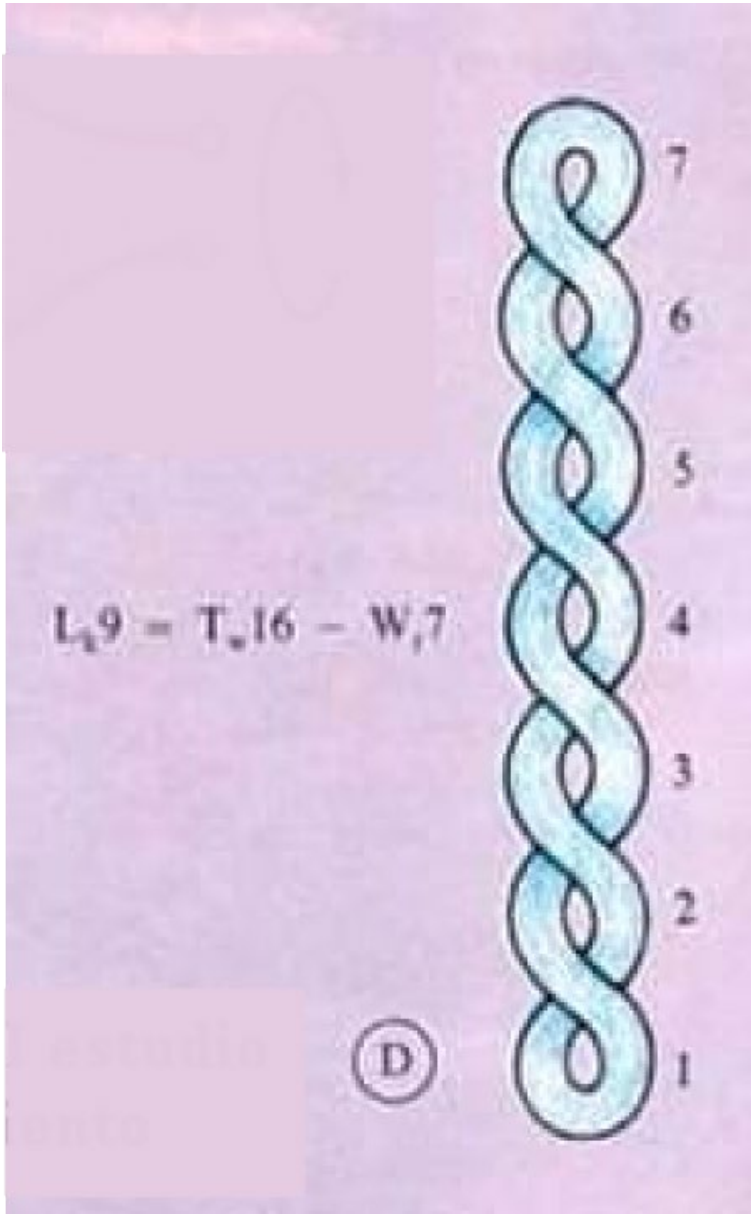


Si a continuación liberamos a la molécula y le permitimos que adopte una configuración compatible con una situación de reposo, sucederá lo ilustrado por el caso D:

Como el ADN es ahora circular, la cantidad de veces que una de las cadenas se envuelve sobre la otra no puede modificarse y en consecuencia L_k es constante.
Por el contrario, el número de vueltas de la doble hélice vuelve a su situación original y por consiguiente T_W aumenta.

En tales condiciones es necesario un W_r negativo con el fin de mantener iguales los dos componentes de la ecuación
$L_k = T_W \pm W_r$

El resultado final será un ADN circular superenrollado con un número de vueltas a la derecha correspondiente a $W_r = -7$



3. MODELOS DINÁMICOS DEL ADN

Modelos lineales
Modelo de cadena única (ADN y ARN)

Consideraciones:

- La interacción entre discos (bases) es armónica.
- Solo se considerarán movimientos longitudinales y rotacionales de los discos.

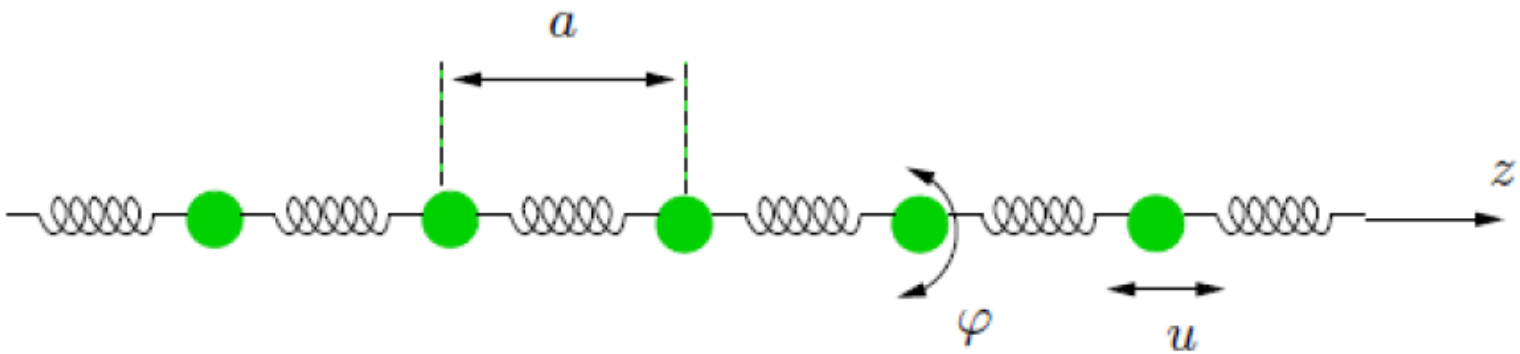
Definiciones:

- $u_n(t)$ es el desplazamiento longitudinal del n-ésimo disco respecto a su posición de equilibrio en el instante t
- $\varphi(t)$ el como el desplazamiento angular
- Las masas, constantes elásticas, de torsión y momentos de inercia son las mismas: **cadena homogénea**
- Las amplitudes de las oscilaciones internas son pequeñas

Escribimos el Hamiltoniano mediante la aproximación armónica como: $H = H_l + H_r + H_{l-r}$

$$\begin{cases} H_l = \sum_{n=1}^{N} \frac{1}{2} m \dot{u}_n^2 + \frac{1}{2} k (u_{n-1} - u_n)^2 \\ H_r = \sum_{n=1}^{N} \frac{1}{2} I \dot{\varphi}_n^2 + \frac{1}{2} \kappa (\varphi_{n-1} - \varphi_n)^2 \end{cases}$$

N es el número de monómeros de la cadena, m la masa de los discos, I momento de inercia, k constante elástica, κ constante de torsión y H_{l-r} es el hamiltoniano de interacción entre ambos movimientos.



Tomando como condiciones de frontera periódicas: $u_n = u_{n+N}$ y $\varphi_n = \varphi_{n+N}$. Y suponiendo que H_{l-r} es constante, las ecuaciones de movimiento quedan de la siguiente forma:

$$m\ddot{u}_n - k(u_{n+1} - 2u_n + u_{n-1}) = 0 \qquad I\ddot{\varphi}_n - \kappa(\varphi_{n+1} - 2\varphi_n + \varphi_{n-1}) = 0$$

Sistema lineal de 2N-ecuaciones diferenciales desacopladas, cuyas soluciones típicas son las ondas planas

$$u_n(t) = u_{0n}\, exp\{i(qna - \omega_l t)\} \qquad \varphi_n(t) = \varphi_{0n}\, exp\{i(qna - \omega_r t)\}$$

q es el numero de onda, a es la distancia entre dos discos cualesquiera (sup. Cte).
Las frecuencias longitudinales y rotacionales son:

$$\omega_t = \frac{2k}{m}(1 - \cos qa) \qquad \omega_r = \frac{2\kappa}{m}(1 - \cos qa)$$

En el límite continuo de las ecuaciones anteriores, obtenemos un modelo continuo de tipo cuerda elástica en vez de un modelo discreto de discos. Las ecuaciones serán

$$\frac{m}{a}\ddot{u}_n = (ka)\frac{u_{n+1}-u_n}{a^2} - (ka)\frac{u_n - u_{n-1}}{a^2}$$

$$u(z,t) = u_0\, exp\{i(qz-\omega_l t)\} \qquad \varphi(z,t) = \varphi_0\, exp\{i(qz-\omega_l t)\}$$

$$\omega_r = \sqrt{\frac{\chi}{\iota}}q \qquad \omega_l = \sqrt{\frac{K}{\rho}}q \qquad \chi = \lim_{a\to 0}\kappa a$$

Donde ρ es la densidad de masa por unidad de longitud, ι es la densidad lineal del momento de inercia

Es decir, a través de esta cadena se desplaza una onda viajera cuyas velocidades longitudinal y rotacional son respectivamente

$$v_l = \frac{\partial \omega_l}{\partial q} = \sqrt{\frac{K}{\rho}} \qquad v_r = \frac{\partial \omega_r}{\partial q} = \sqrt{\frac{\chi}{\rho}}$$

Deficiencias:

El no tiene en cuenta el movimiento perpendicular al eje z

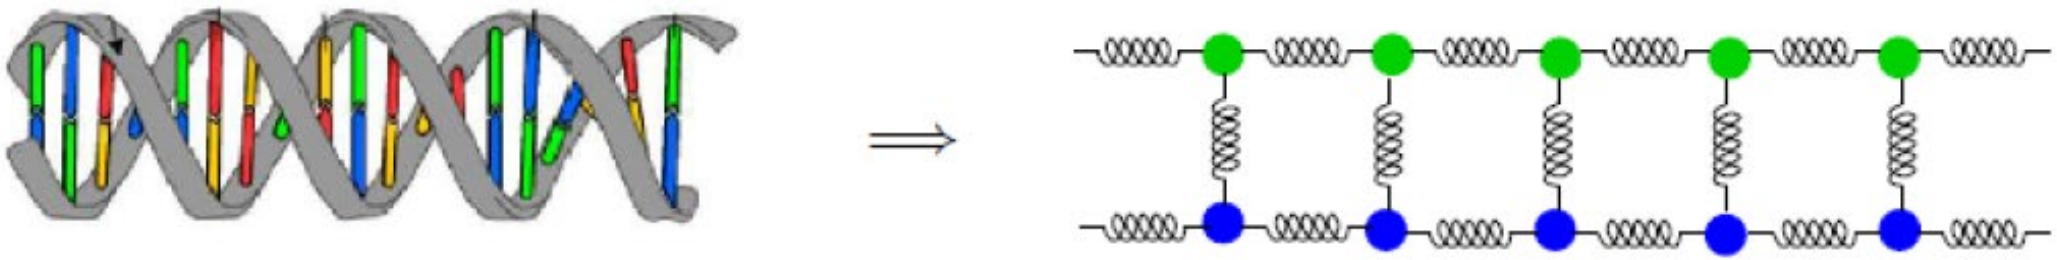
La energía no esta localizada (transcripción)

Aproximación términos armónicos: baja amplitud de la onda

Soluciones

Modelos no lineales

Modelo de doble única (ADN)



Sean u los movimientos longitudinales, y los transversales y φ los movimientos rotacionales de los discos. El hamiltoniano será:

$$H = H_l^{(1)} + H_l^{(2)} + H_r^{(1)} + H_r^{(2)} + H_t^{(1)} + H_t^{(2)} + H^{(1-2)}$$

donde $H_i^{(j)}$ con $i = l, r, t$ y $j = 1, 2$ son respectivamente los movimientos longitudinales, los rotacionales y los transversales de cada cadena, y $H^{(1-2)} = H_l^{(1-2)} + H_r^{(1-2j)} + H_t^{(1-2j)}$ es la suma de las interacciones entre ambas cadenas asociadas a los correspondientes movimientos longitudinales, rotacionales y transversales.

$$H_l^{(j)} = \sum_{n=1}^{N} \frac{1}{2} m \dot{u}_{n,j}^2 + \frac{1}{2} k \left(u_{n-1,j} - u_{n,j}\right)^2$$

$$H_t^{(j)} = \sum_{n=1}^{N} \frac{1}{2} m \dot{y}_{n,j}^2 + \frac{1}{2} b \left(y_{n-1,j} - y_{n,j}\right)^2$$

$$H_r^{(j)} = \sum_{n=1}^{N} \frac{1}{2} I \dot{\varphi}_{n,j}^2 + \frac{1}{2} \varkappa \left(\varphi_{n-1,j} - \varphi_{n,j}\right)^2$$

La interacción entre las cadenas puede aproximarse de la siguiente forma:

$$H^{(1-2)} = \sum_{n=1}^{N} \frac{\alpha}{2} \left(u_{n,1} - u_{n,2}\right)^2 + \sum_{n=1}^{N} \frac{\beta}{2} \left(\varphi_{n,1} - \varphi_{n,2}\right)^2 + \sum_{n=1}^{N} \frac{\gamma}{2} \left(y_{n,1} - y_{n,2}\right)^2$$

Donde α, β y γ son constantes

6.8 MÉTODOS DE SIMULACIÓN

Dinámica molecular: promedio temporal
Monte Carlo: promedio ensamblado

En ambos casos se obtienen promedios de estructura y diferentes propiedades que se aproximan a los valores medidos experimentalmente

PROMEDIOS TEMPORALES Y PROMEDIOS DE ENSAMBLADO

Propiedad A: dependiente de las posiciones y momentos de todas las partículas

$$A(\vec{p}^N(t), \vec{r}^N(t))$$

$$\langle A \rangle = \iint d\vec{p}^N \, d\vec{r}^N A(\vec{p}^N, \vec{r}^N) \rho(\vec{p}^N, \vec{r}^N)$$

$\rho(\vec{p}^N, \vec{r}^N)$ Densidad de probabilidad del colectivo , la probabilidad de encontrar un a configuración determinada

BREVE DESCRIPCIÓN DEL MÉTODO DE DINÁMICA MOLECULAR

- Calcula la dinámica del sistema a partir de la cual pueden calcularse los promedios temporales de las propiedades.
- Método determinístico.
- Genera una trayectoria.

BREVE DESCRIPCIÓN DEL MÉTODO DE MONTE CARLO

- Las sucesivas configuraciones no están conectadas en el tiempo.
- Genera configuraciones aleatoriamente y utiliza un conjunto de criterios para decidir aceptar o no la configuración.

DIFERENCIAS ENTRE LOS MÉTODOS DE DINÁMICA MOLECULAR Y MONTE CARLO

- MD provee información sobre la dependencia temporal de las propiedades del sistema. No hay relación temporal entre dos configuraciones sucesivas en MC.



Parámetros de simulación
Δt, t_{max}, box...

Condiciones iniciales:
Coordenadas y velocidad $(\vec{r_i}, \vec{v_i})$

Cálculo de las fuerzas en función del tiempo (t_n).
$\vec{F_i} = -\nabla_i V(\vec{r_i}, \ldots, \vec{r_N})$

Resol. Eq. mov. $t_{n+1} = t_n + \Delta t$
$\vec{r_i}(t_n) \rightarrow \vec{r_i}(t_{n+1})$ $\vec{v_i}(t_n) \rightarrow \vec{v_i}(t_{n+1})$

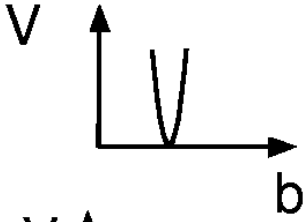
Cálculo de propiedades de interés,
Almacenamiento datos: r_i, v_i, T, p, E...

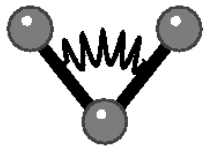
$t < t_{max}$

Fin

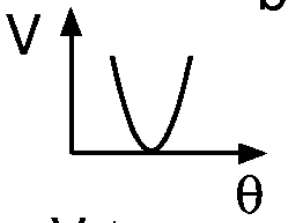


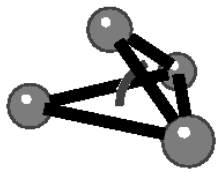
$$V_B = \sum_{\text{Bindungen}} \frac{1}{2} K_b (b - b_0)^2$$



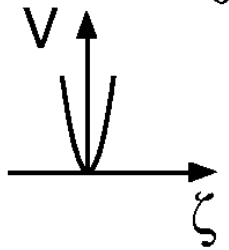


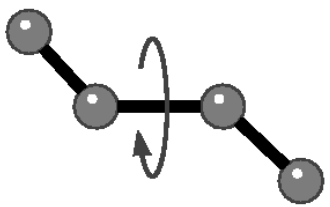
$$V_a = \sum_{\text{Winkel}} \frac{1}{2} K_\theta (\theta - \theta_0)^2$$



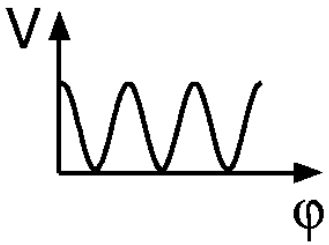


$$V_{imp} = \sum_{\text{Extraplanarwinkel}} \frac{1}{2} K_\zeta (\zeta - \zeta_0)^2$$



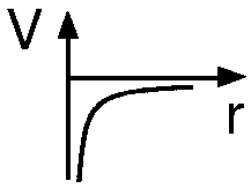


$$V_D = \sum_{\text{Dihedralwinkel}} K_\varphi [1 + \cos(n\varphi - \delta)]$$



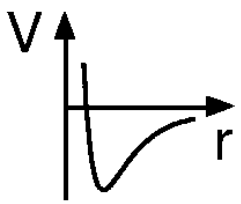


$$V_q = \sum_{\text{Paare(i,j)}} q_i q_j / (4\pi\epsilon_0\epsilon_r r_{ij})$$

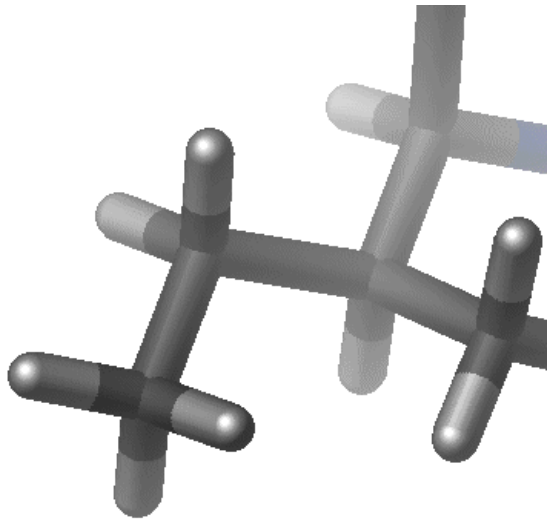




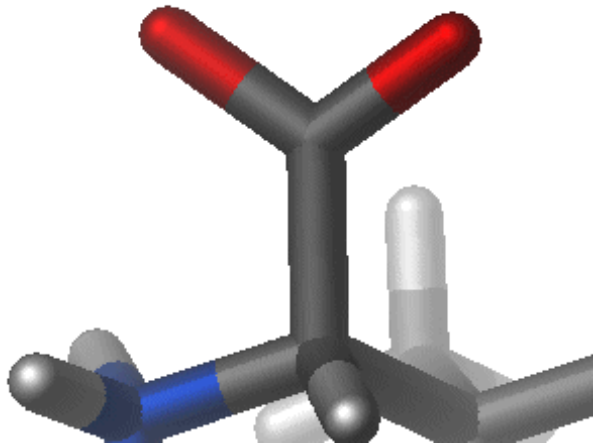
$$V_{vdW} = \sum_{\text{Paare(i,j)}} C_{12}(i,j)/r_{ij}^{12} - C_6(i,j)/r_{ij}^6$$



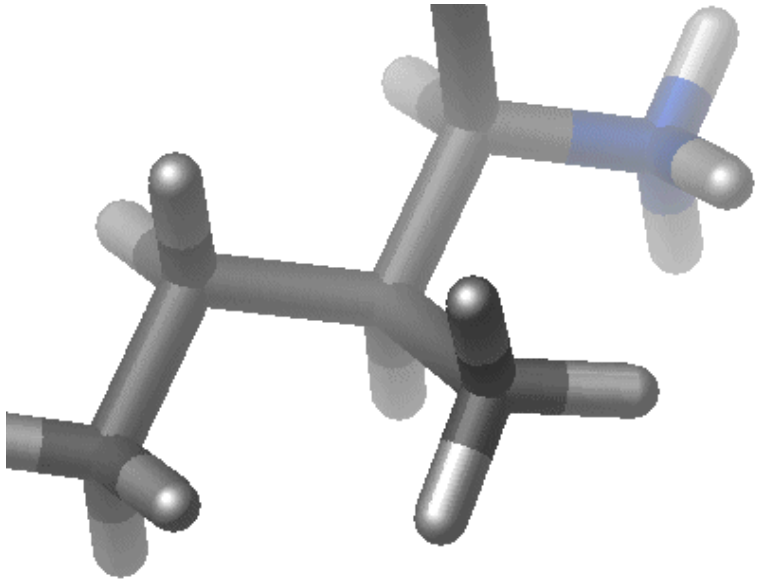
Enlaces covalentes



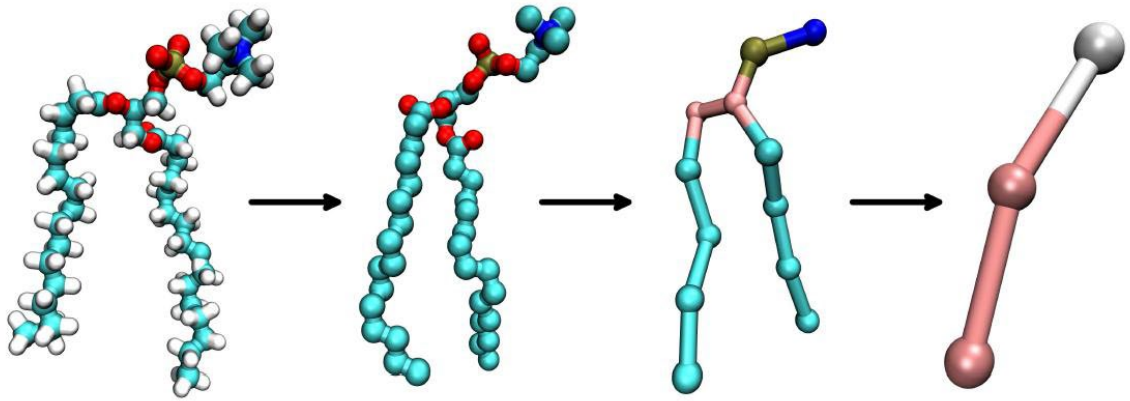
Ángulos

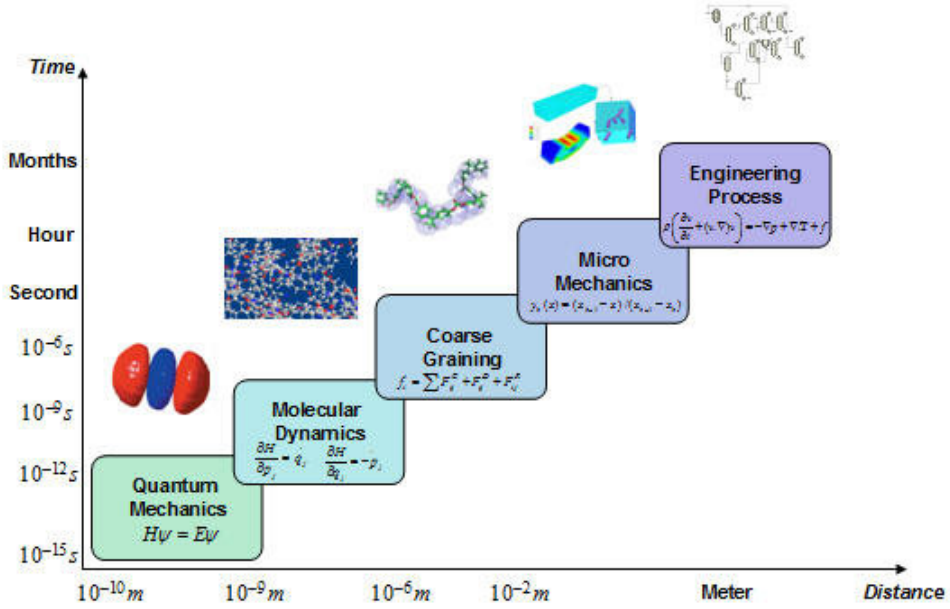


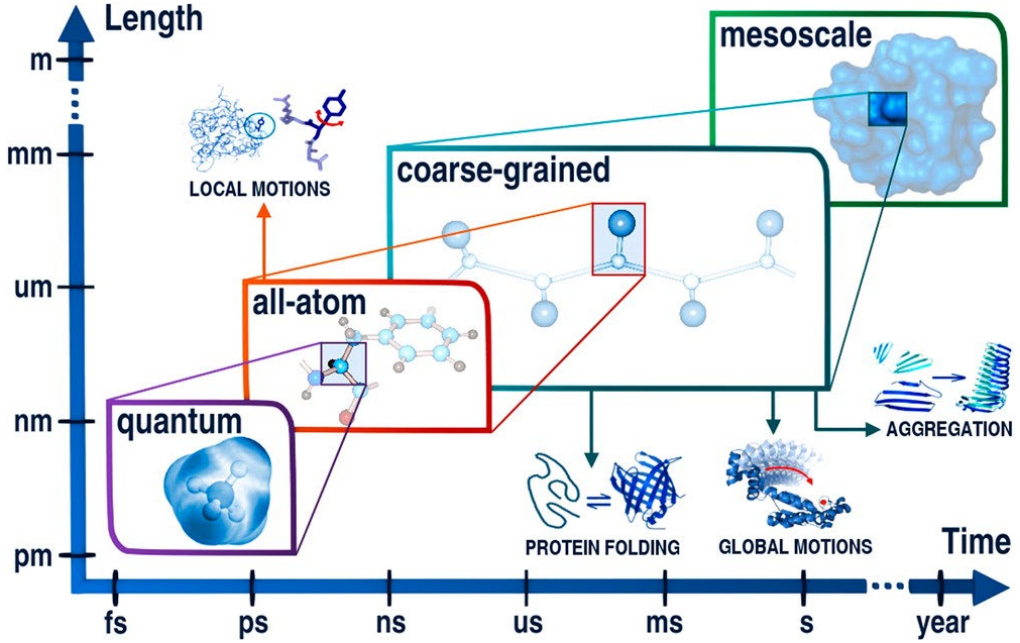
Ángulos diédricos propios (rotaciones)

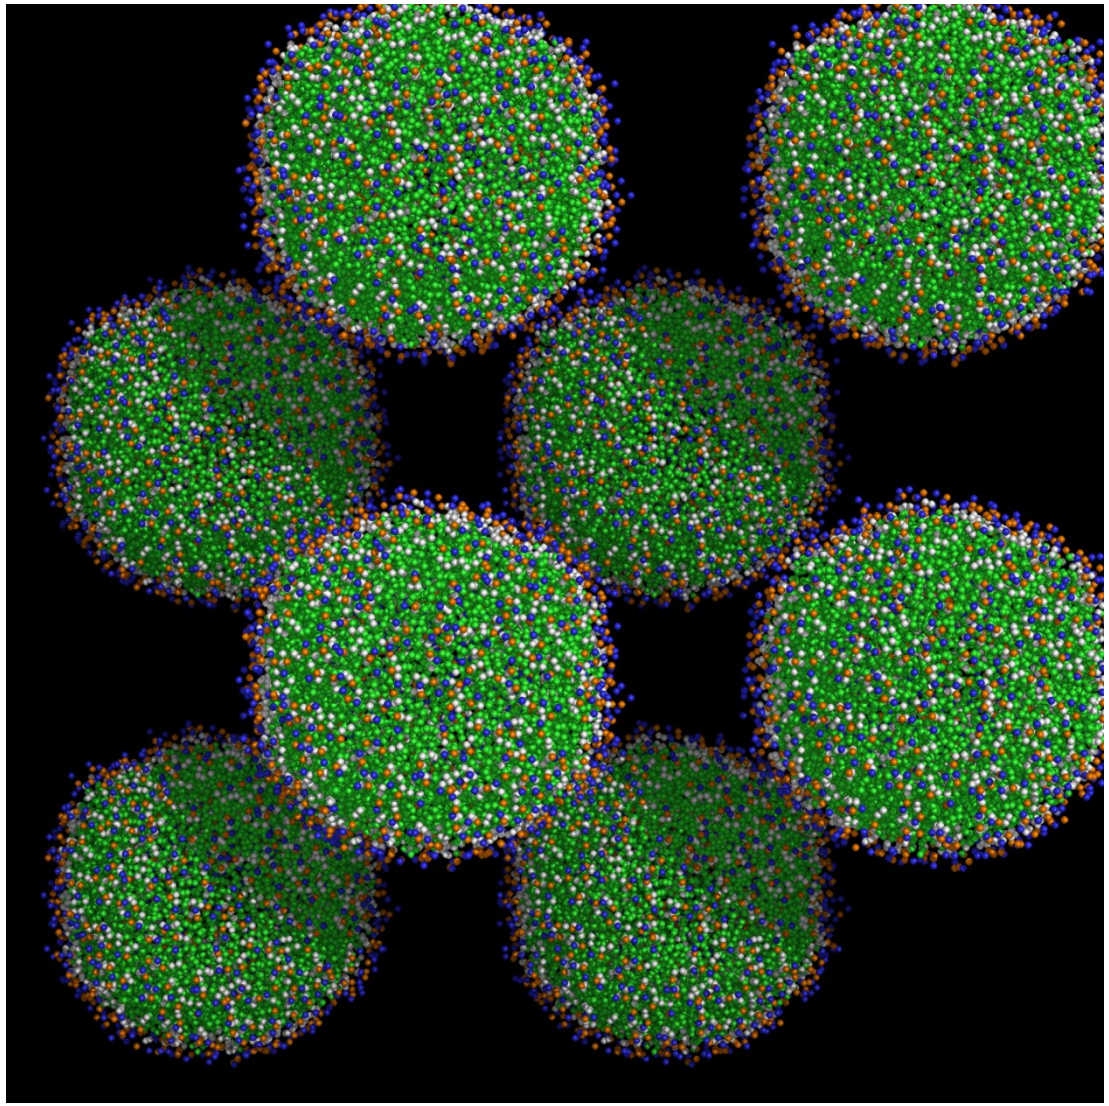


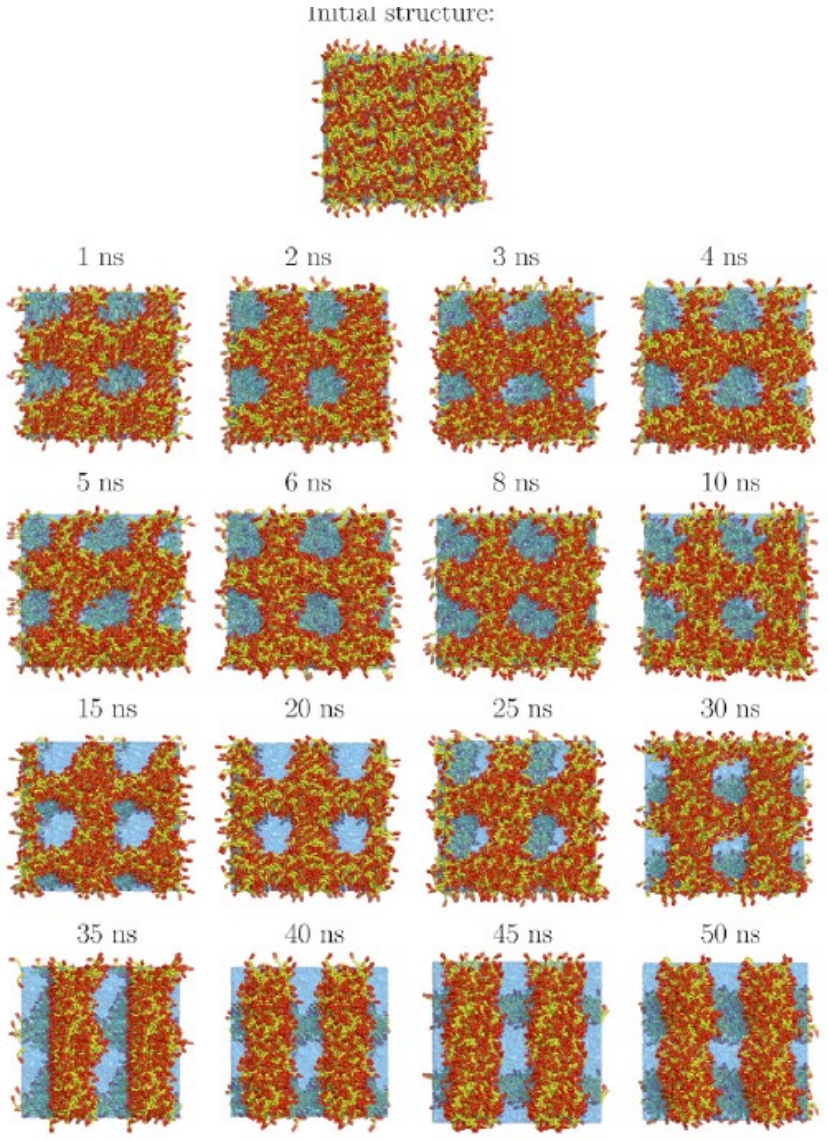
Simulaciones Coarse-Grain



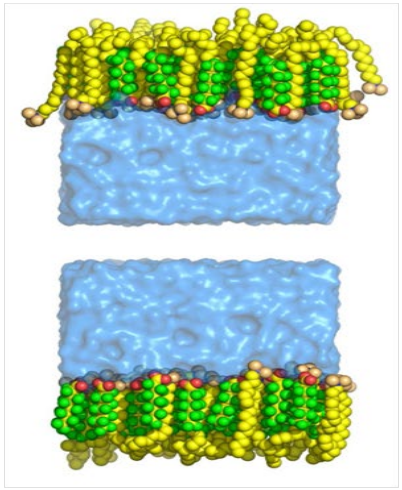


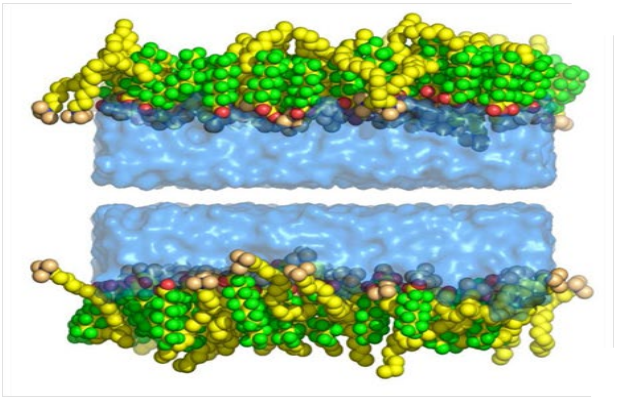


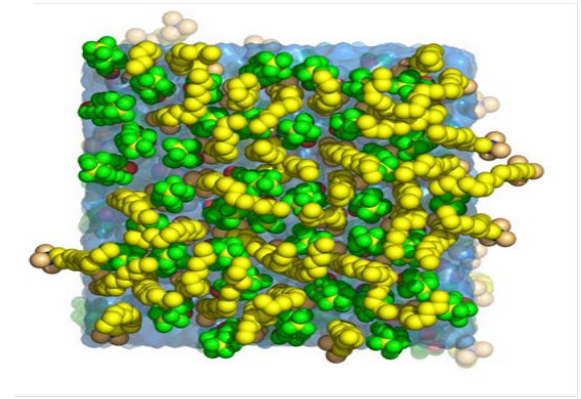


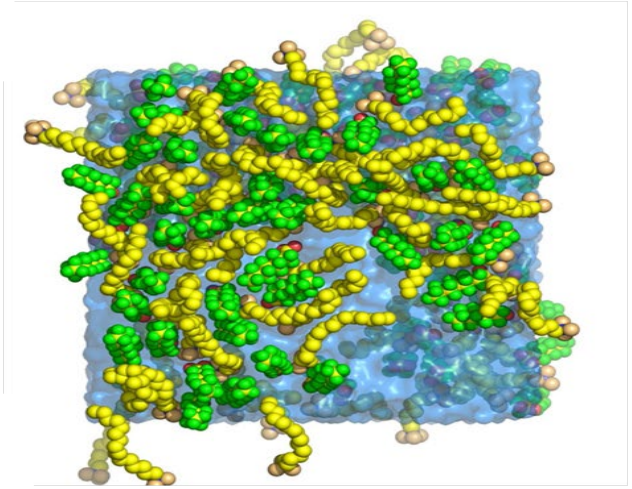

Initial structure:
1 ns
2 ns
3 ns
4 ns
5 ns
6 ns
8 ns
10 ns
15 ns
20 ns
25 ns
30 ns
35 ns
40 ns
45 ns
50 ns

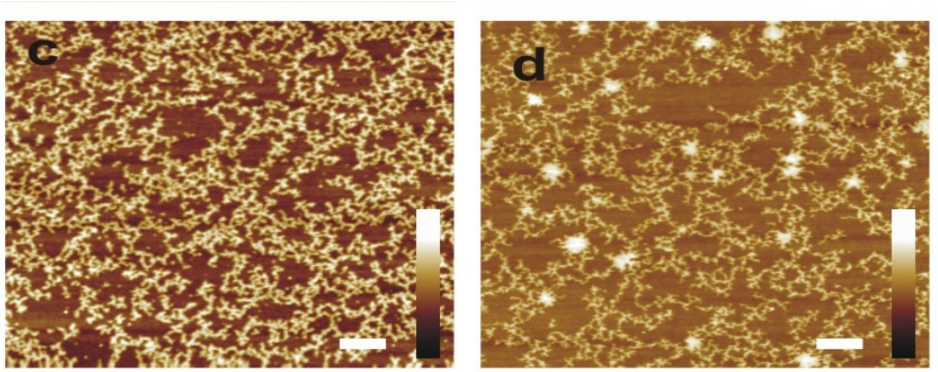
Langmuir Monolayers of a Hydrogenated/Fluorinated Catanionic Surfactant: From the Macroscopic to the Nanoscopic Size Scale

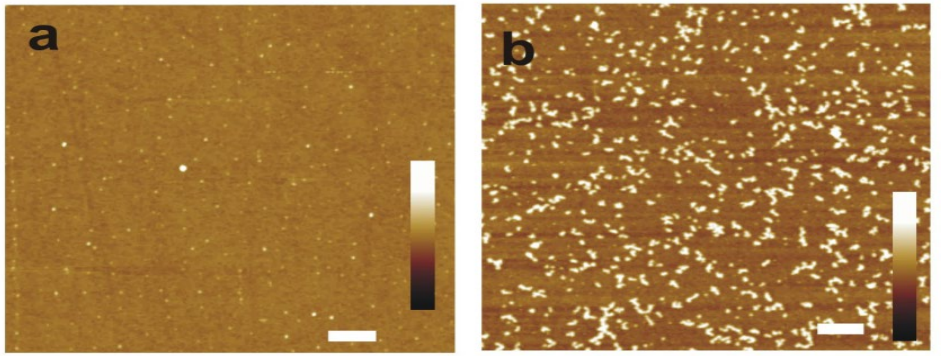


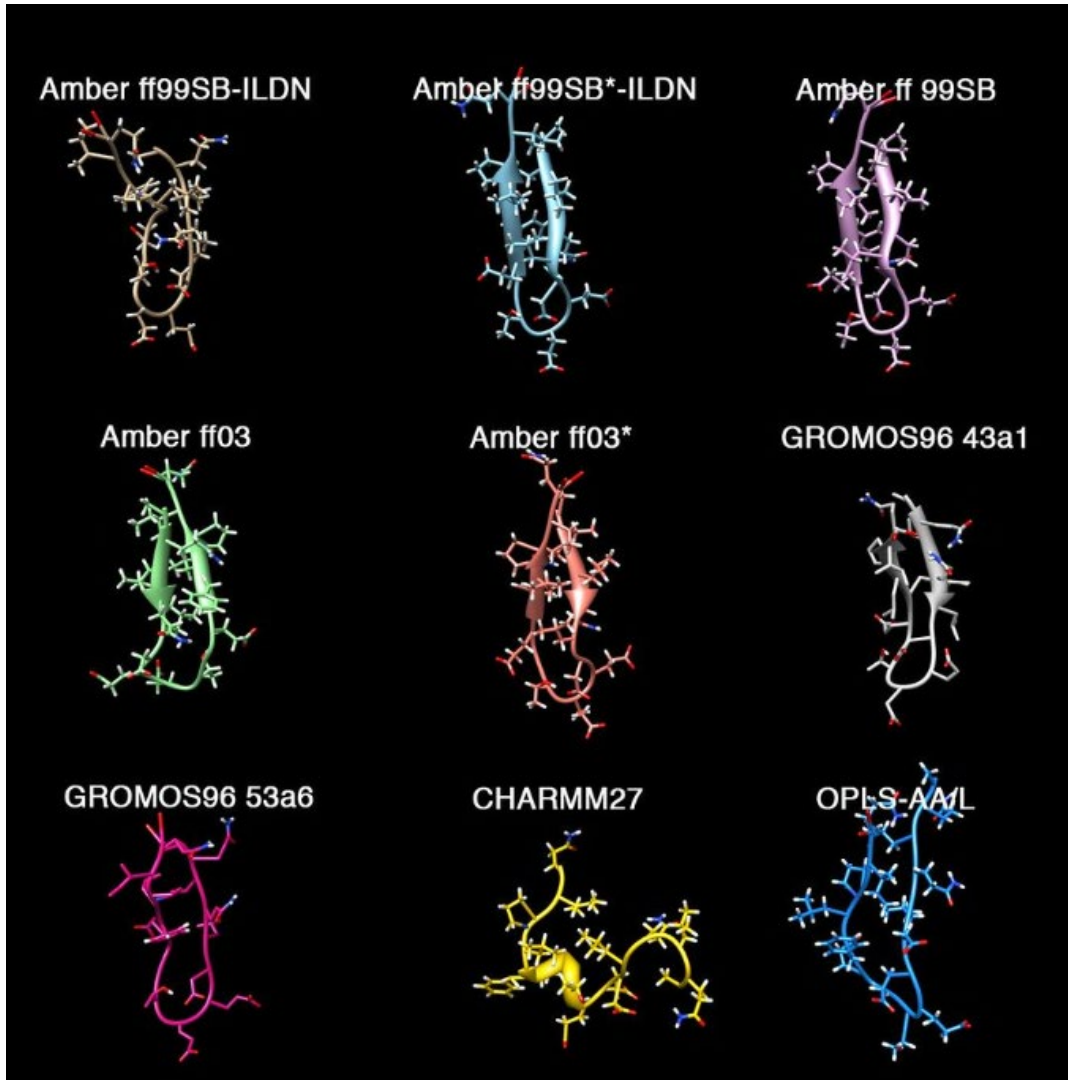


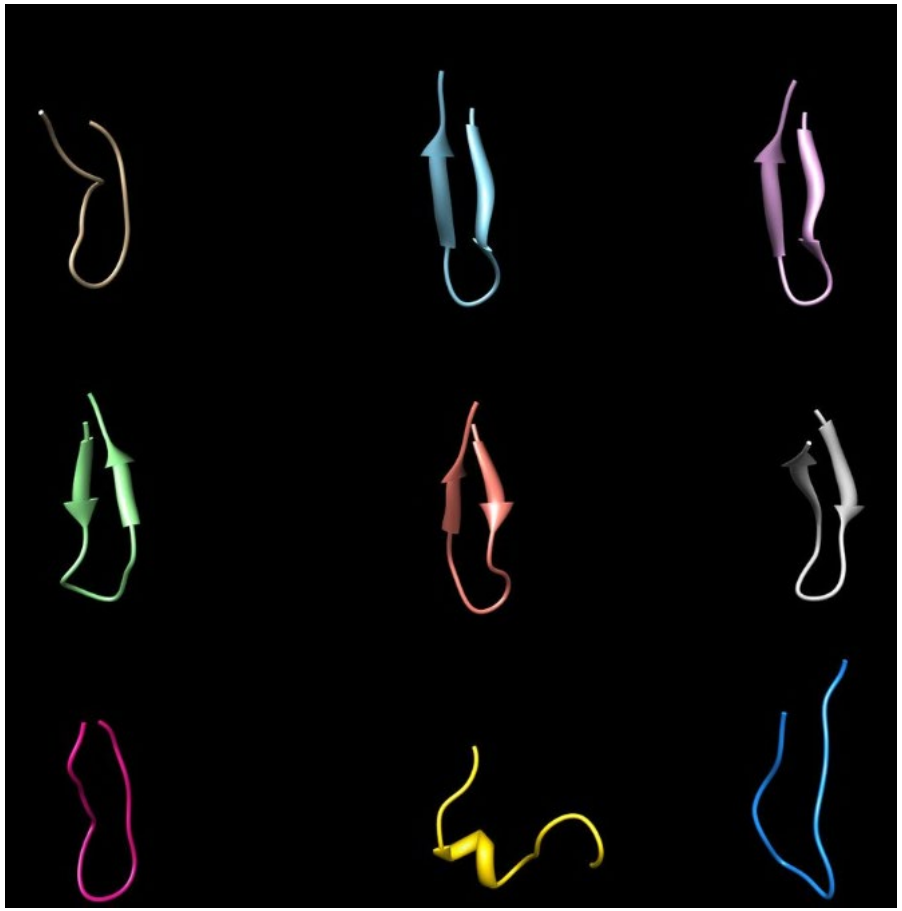









Amber ff99SB-ILDN
Amber ff99SB*-ILDN
Amber ff 99SB
Amber ff03
Amber ff03*
GROMOS96 43a1
GROMOS96 53a6
CHARMM27
OPLS-AA/L



7. DESCRIPTORES MOLECULARES

- ✓ “La naturaleza es un libro escrito con signos matemáticos” (Galileo)

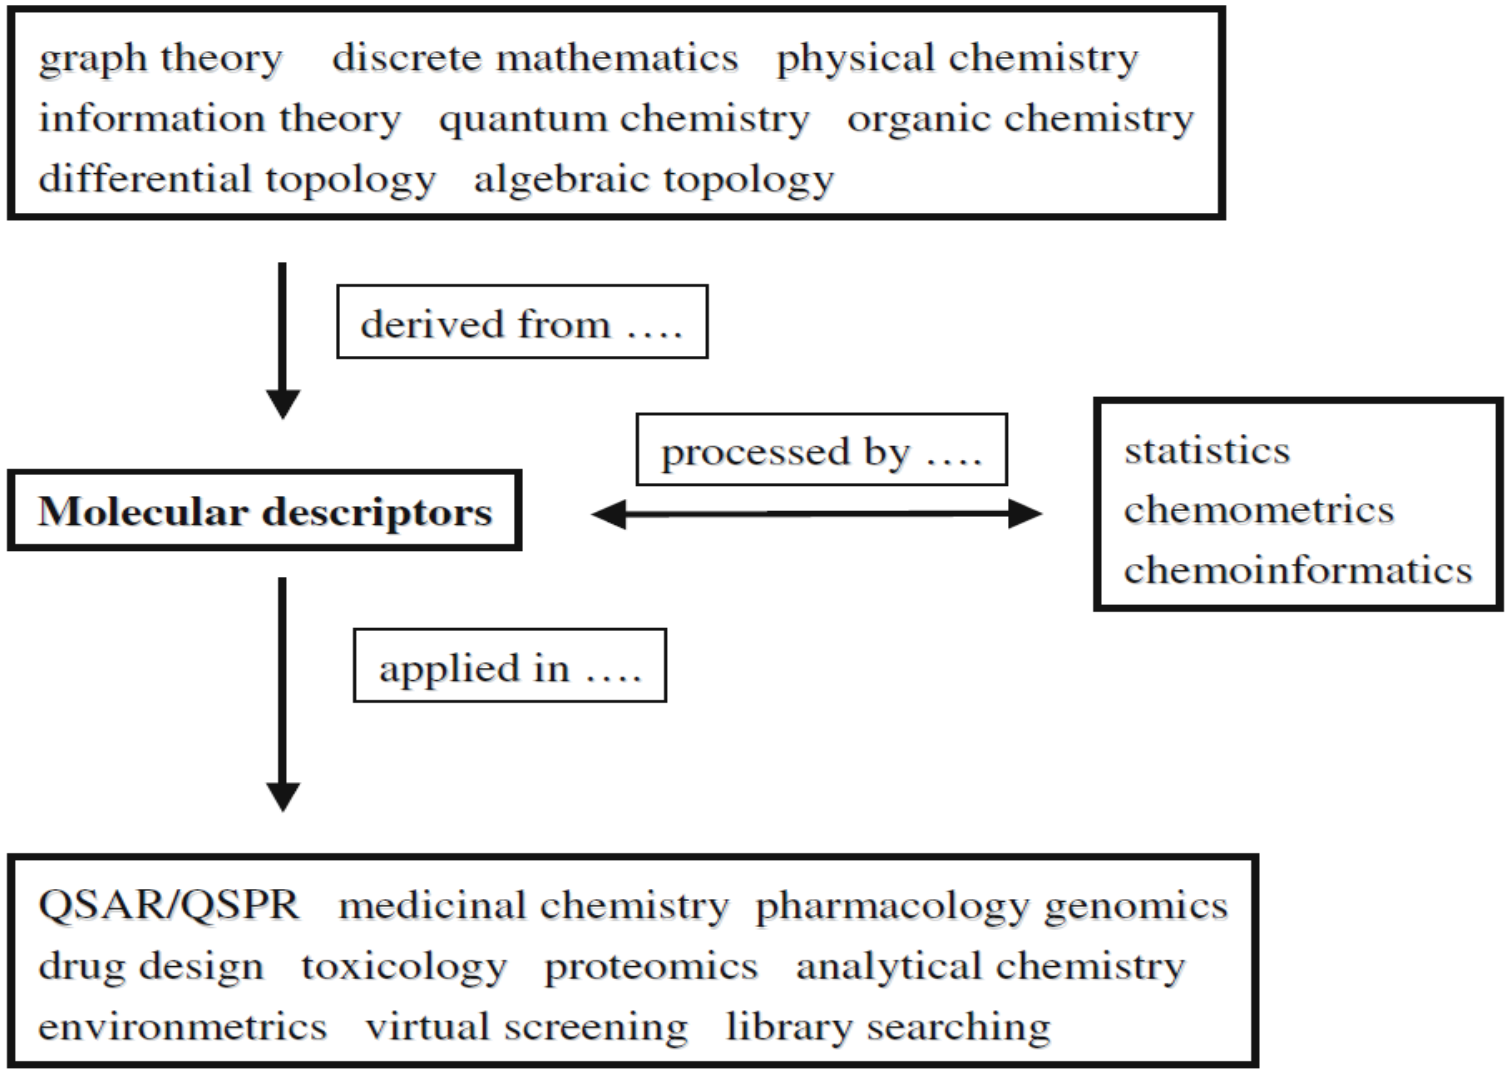
- ✓ Los descriptores moleculares son representaciones matemáticas formales de una molécula, obtenidas por un algoritmo bien especificado, y aplicadas a una representación molecular definida o a un procedimiento experimental bien especificado.

- ✓ Los descriptores moleculares se obtienen aplicando principios de varias teorías diferentes, como la física cuántica, la teoría de la información, la química orgánica, la teoría de grafos.

- ✓ Biología, toxicología, química, física, medicina o farmacia.

- ✓ >10000

- ✓ Todeschini, R., Consonni, V. (2008). *Handbook of molecular descriptors*. John Wiley & Sons.


graph theory discrete mathematics physical chemistry
information theory quantum chemistry organic chemistry
differential topology algebraic topology
derived from ....
Molecular descriptors
processed by ....
statistics
chemometrics
chemoinformatics
applied in ....
QSAR/QSPR medicinal chemistry pharmacology genomics
drug design toxicology proteomics analytical chemistry
environmetrics virtual screening library searching

Por regla general los descriptores moleculares deben satisfacer una serie de propiedades básicas:

- Interpretación estructural
- Buena correlación con al menos una propiedad
- Permitir la discriminación de isómeros
- Aplicable a la estructura local
- Generalizable a descriptores superiores
- Independencia
- Simplicidad
- No se basará en las propiedades
- No debe relacionarse trivialmente con otros descriptores
- Permitir una construcción eficiente
- Usar conceptos estructurales conocidos
- Mostrar la dependencia correcta con el tamaño
- Mostrar cambios graduales con cambio graduales de las estructuras

TIPOS DE DESCRIPTORES

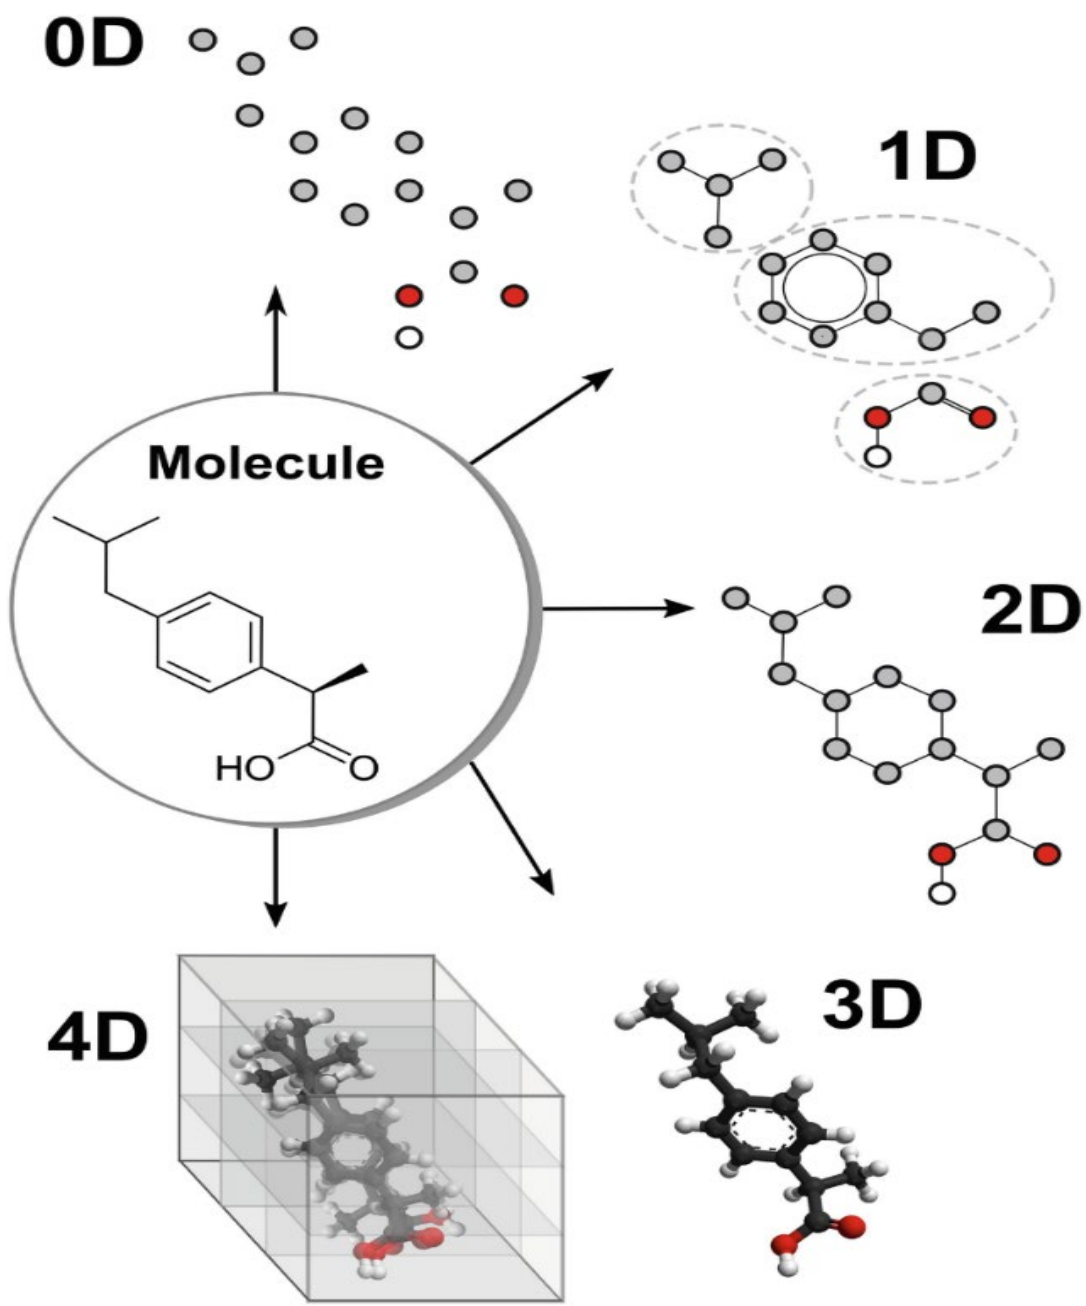
- Experimentales: en general propiedades físico-químicas: log P, refractividad molar, momento dipolar, polarizabilidad....
- Teóricos: se derivan de una representación simbólica de la molécula).

La diferencia fundamental entre ambos es que los teóricos no contienen errores experimentales.

Cada descriptor solo tiene en cuenta una pequeña parte de la información de la molécula,.

Los descriptores teóricos suelen clasificarse en función de su "dimensión":

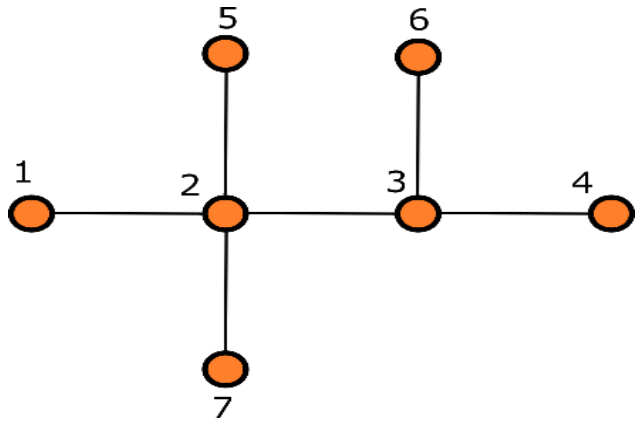
- 0D – peso molecular, numero de átomos de algún tipo
- 1D – listas parciales de fragmentos, grupos funcionales, sustituyentes (Crippen, PSA, SMARTS)
- 2D – se obtienen a partir de algún algoritmo aplicado a alguna representación topológica (Balaban, Randic, Wiener, kappa....)
- 3D – su origen son las coordenadas tridimensionales de la molécula (3D WHIM, 3D autocorrelation.....)
- 4D – derivan de las energías de interacción entre la molécula y su entorno (JCHEM conformer, CORINA, gold set....)


0D
1D
Molecule
HO
O
2D
4D
3D

INDICES TOPOLOGICOS

Un grafo molecular es una representación topológica de una molécula, es un diagrama donde los vértices representan átomos y las aristas enlaces covalentes.
H-depleted molecular graph)

La nomenclatura general es de la forma G=(V,E).



El grafo superior V ={1,2,3,4,5,6,7} y E={{1,2},{2,3}, {2,5}, {2,7},{3,4},{3,6}}

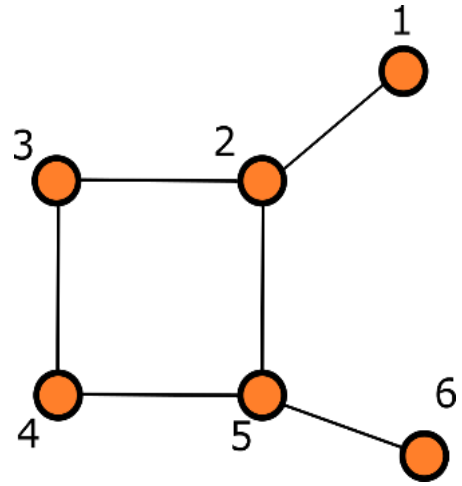
Se defina un camino (walk) como una secuencia de vértices W=(v1,v2,v3,.....,vk) donde vj $\in$ E.

La longitud del camino es el número de aristas que recorridas. Si el camino empieza y termina en el mismo vértice se dice camino cerrado

Una senda o camino euleriano (path) es un camino en el que no se repite ningún vértices.

En la figura {1,2,3,2,5} camino,
{1,2,3,4,5} senda.

Si comienza y termina en el mismo vértice se dice un ciclo



La distancia topológica es el camino más corto entre dos vértices (d_{15}=2)
El camino más largo se denomina detour distance *(δ15=4)*.

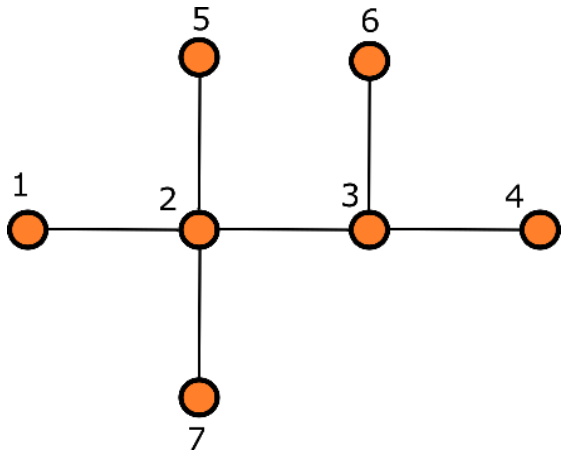
La matriz de adyacencia representa el conjunto de conexiones entre pares adyacentes de átomos

$$\begin{pmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

La mayoría de los descriptores moleculares se basan en funciones derivadas de las matrices del grafo o en invariantes de vértice adyacentes.

Veamos algunos ejemplos de ambos

Grado de vértice atómico (δ_i), es la suma de las filas de la matriz de adyacencia



$$\begin{pmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{matrix} \delta_i \\ 1 \\ 4 \\ 3 \\ 1 \\ 1 \\ 1 \\ 1 \end{matrix}$$

La matriz de distancias representa la distancia mínima entre dos vértices (el mínimo de aristas)

S_i es el grado de los vértices de la matriz distancia. Se obtiene de la suma de las filas de la matriz distancia

η_i, es la excentricidad de los vértices (máximo de la fila correspondiente), su valor es mínimo para los vértices mas céntricos del grafo

$$\begin{pmatrix} 0 & 1 & 2 & 3 & 2 & 3 & 2 \\ 1 & 0 & 1 & 2 & 1 & 2 & 1 \\ 2 & 1 & 0 & 1 & 2 & 1 & 2 \\ 3 & 2 & 1 & 0 & 3 & 2 & 3 \\ 2 & 1 & 2 & 3 & 0 & 3 & 2 \\ 3 & 2 & 1 & 2 & 3 & 0 & 3 \\ 2 & 1 & 2 & 3 & 2 & 3 & 0 \end{pmatrix} \quad \begin{matrix} S_i & \eta_i \\ 13 & 3 \\ 8 & 2 \\ 9 & 2 \\ 14 & 3 \\ 13 & 3 \\ 14 & 3 \\ 13 & 3 \end{matrix}$$

Matriz detour: matrix compuesta por elementos $L(i,j)$, siendo la longitud de la distancia más larga entre los vértices i, j

Matriz laplaciana: representa cuantas ramificaciones existen en un grafo

$$\begin{pmatrix} 1 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 4 & -1 & 0 & -1 & 0 & -1 \\ 0 & -1 & 3 & -1 & 0 & -1 & 0 \\ 0 & 0 & -1 & 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & -1 & 0 & 0 & 1 & 0 \\ 0 & -1 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

Los índices simples derivados de un grafo molecular se llaman índices topológicos (TI). Pueden ser sensibles a una o más características estructurales de la molécula, como el tamaño, la forma, la simetría, la ramificación y la ciclicidad, y también pueden codificar la información química relativa al tipo de átomo y la multiplicidad de enlaces. Las funciones más comunes para derivar los índices topológicos a partir de las matrices topológicas son:

$D_1(\mathbf{M};\alpha,\lambda) = \alpha \sum_{i=1}^{n}\sum_{j=1}^{n}[\mathbf{M}]_{ij}^{\lambda}$	En D_1 y D_2 los valores más comunes son $\alpha = 1/2$ y $\lambda = 1$
$D_2(\mathbf{M};\alpha,\lambda) = \alpha \sum_{i=1}^{n}\sum_{j=1}^{n}a_{ij}[\mathbf{M}]_{ij}^{\lambda}$	Restringida a pares de vértices adyacentes, siendo a_{ij} los elementos de la matriz de adyacencia iguales a uno para los pares de vértices adyacentes y cero en caso contrario.
$D_3(\mathbf{M};\alpha) = \alpha \det(\mathbf{M})$	Genera descriptores derivados del determinante
$D_4(\mathbf{M};\alpha,\lambda) = \alpha \sum_{i=0}^{n}\left\lvert c\left(Ch(\mathbf{M};x)\right)_i^{\lambda}\right\rvert$	Genera descriptores a partir de combinaciones lineales de los coeficientes del polinomio característico de la matriz
$D_5(\mathbf{M}) = f(\Lambda(\mathbf{M}))$	Se basa en los valores propios de la matriz. Los descriptores moleculares relacionados se llaman índices espectrales
$D_6(\mathbf{M};\alpha,\lambda) = \alpha \sum_{k=1}^{K}\left(\prod_{i=1}^{n_k} VS_i(\mathbf{M})\right)_k^{\lambda}$	$VS_i(\mathbf{M})$ representa la suma de la i-ésima fila de la matriz, K el número total de fragmentos del grafo, n_k el número de vértices del fragmento k. (LOVIs)
$D_7(\mathbf{M};\alpha,\lambda) = \alpha \sum_{i=1}^{n}\sum_{j=1}^{n}\left([\mathbf{M}]_{ij}^{\lambda} + [\mathbf{M}]_{ij}\right)$	Para valores de $\alpha = 1/2$ y $\lambda = 2$ genera los índices de tipo hiper-Wiener (generalizaciones de la suma de las distancias entre todos los pares de vértices del grafo)
$D_8(\mathbf{M};\alpha,\lambda) = \alpha\, max_{ij}([\mathbf{M}]_{ij}^{\lambda})$	Genera descriptores basados en distancias máximas

Funciones derivadas de invariantes de vértice adyacentes, L. L_i y L_j son invariantes asociados a los vértices v_i y v_j, A el número de vértices, V el conjunto de los vértices, $\delta(d_{ij};k)$ la función delta de Dirac: uno para pares de vértices situados a una distancia topológica d_{ij} igual a k y cero en caso contrario; a_{ij} elemento de la matriz de adyacencia iguales a 1 para vértices adyacentes y cero en caso contrario. D_4, para $\alpha = 1$ y $\lambda = 1/2$, fórmulas Randic. En D_6 el sumatorio es sobre un cierto número de fragmentos, K, con un número de vértices n_K. D_7 descriptores de autocorrelación. D_8 autocorrelación máxima.

$D_1(L;\alpha,\lambda) = \alpha \sum_{i=1}^{n} L_i^{\lambda}$	$D_5(L;\alpha,\lambda) = \alpha \sum_{i=1}^{A}\sum_{j=1}^{A} (L_i L_i)^{\lambda} \quad j \neq i$
$D_2(L;\alpha,\lambda) = \alpha \left(\prod_{i=1}^{A} L_i\right)^{\lambda}$	$D_6(L;\alpha,\lambda) = \alpha \sum_{k=1}^{K} \left(\prod_{i=1}^{n_k} L_i\right)_k^{\lambda}$
$D_3(L;\alpha) = \alpha \max_{i\in V}(L_i)$	$D_7(L;\alpha,\lambda) = \alpha \sum_{i=1}^{A}\sum_{j=1}^{A} (L_i L_i)^{\lambda}\, \delta(d_{ij};k)$
$D_4(L;\alpha,\lambda) = \alpha \sum_{i=1}^{A}\sum_{j=1}^{A} a_{ij}(L_i L_i)^{\lambda}$	$D_8(L;\alpha,\lambda,k) = \alpha \max_{i,j\in V}\left[(L_i L_i)^{\lambda}\, \delta(d_{ij};k)\right]$

Algunos ejemplos

- **Hydrophilic index (Hy)**

$$Hy = \frac{(1+nHy)log(1+nHy) + nC\left({}^{1}/_{n}\, log({}^{1}/_{n}) + \sqrt{{}^{nHy}/_{n^2}}\right)}{log(1+n)}$$

nHy nº grupos hidrofílicos,

nC nº átomos de carbono,

n nº total de átomos (excepto H),

-1<Hy<3.64

- **Índice de Weber**

$$W = \frac{1}{2}\sum_{i=1}^{A}\sum_{j=1}^{A} d_{ij}$$

d_{ij} distancia topológica

Balaban distance connectivity index

$$J = \frac{B}{C+1}\sum \left(\sigma_i \sigma_j\right)^{-1/2}$$

σ son las sumas de las filas de la matriz de distancia, B el número de aristas y C=B-número de vértices + número de vértices conectados.

Indices de conectividad de átomos de orden m

$${}^{0}\chi = \sum_a \delta_a^{-1/2} \qquad {}^{1}\chi = \sum_b \left(\delta_i \delta_j\right)_b^{-1/2}$$

$${}^{2}\chi = \sum_{k=1}^{{}^{2}P} \left(\delta_i \delta_l \delta_j\right)_b^{-1/2} \qquad \ldots {}^{m}\chi_q = \sum_{k=1}^{{}^{m}P} \left(\prod_{a=1}^{n} \delta_a\right)_k^{-1/2}$$

${}^{m}P$ número de sendas de orden m. q clase de subgrafo (senda, camino, cadena)

Es un índice útil que refleja patrones de ramificación y discriminación entre isómeros

Algunos ejemplos de descriptores de proteínas

- **Contenido de aminoácidos:** la fracción de cada aminoácido en la proteína

$$f(r) = \frac{N_r}{N} \quad r=1,2,3,.....,20$$

N_r nº aminoácidos tipo r y N es la longitud de la secuencia

- **Descriptores de autocorrelación.** Se definen en base a la distribución de diversas propiedades (P) de los aminoácidos en la secuencia.

$$P'_r = \frac{P_r - \bar{P}}{\sigma} \quad \text{donde } \bar{P} = \frac{\sum_{r=1}^{20} P_r}{20} \text{ y } \sigma = \sqrt{\frac{1}{20}\sum_1^{20}(P_r - \bar{P})^2}$$

- **Descriptores de autocorrelación Moreau-Broto.** En este caso d=1,2,3..... es el retraso de la autocorrelación.

$$I(d) = \frac{\frac{1}{N-d}\sum_{i=1}^{N-d}(P_i - \bar{P})(P_{i+d} - \bar{P})}{\frac{1}{N}\sum_{i=1}^{N}(P_i - \bar{P})^2}$$

RECURSOS ON LINE

Descriptores moleculares:

- E-Dragon at VCCLAB (http://www.vcclab.org/lab/edragon/)
- MOLE db (http://michem.disat.unimib.it/mole_db/)
- OCHEM (https://ochem.eu/home/show.do)
- ADAPT (http://research.chem.psu.edu/pcjgroup/adapt.html)
- RDKit (https://www.rdkit.org/docs/index.html)

Descriptores de proteínas y biomoléculas

- ToMoCoMD (http://tomocomd.com)
- PyBioMed (https://pybiomed.readthedocs.io/en/latest/overview.html)
- Profeat (http://bidd.group/cgi-bin/profeat2016/main.cgi)

OTROS SOFTWARES PARA MODELOS QSAR

- BuildQSAR (https://www.profanderson.net/files/buildqsar.php)
- ChemDes (http://www.scbdd.com/chemdes/)